Unidad 2: Limpieza, Transformación y Análisis Exploratorio de Datos

Sitio:	Aulas Virtuales FCFMyN	Imprimido por:	LUCAS EZEQUIEL ACOSTA
Curso:	Laboratorio de Datos - 2026 - Aula1	Día:	jueves, 16 de abril de 2026, 19:34
Libro:	Unidad 2: Limpieza, Transformación y Análisis Exploratorio de Datos		

Tabla de contenidos

1. Limpieza, Transformación y Análisis Exploratorio de Datos

2. Transformación: Normalización, discretización y binarización de variables

3. Análisis exploratorio de datos

4. Análisis univariado

5. Análisis bivariado

1. Limpieza, Transformación y Análisis Exploratorio de Datos

El análisis exploratorio de datos (AED) es un proceso crítico en el campo de la estadística y la ciencia de datos que tiene como objetivo examinar y comprender de manera exhaustiva un conjunto de datos antes de aplicar técnicas estadísticas más avanzadas. Este enfoque se utiliza para revelar patrones, tendencias, relaciones y características notables dentro de los datos, proporcionando una visión inicial que permitirá guiar el camino hacia investigaciones más profundas sobre los mismos.

Durante el análisis exploratorio de datos, se emplean diversas técnicas visuales y estadísticas descriptivas. Esto puede incluir la generación de gráficos, histogramas, diagramas de dispersión y medidas resumidas como la media, la mediana y la desviación estándar, entre otros. La identificación de valores atípicos, la evaluación de la distribución de variables y la detección de posibles correlaciones son aspectos clave del proceso.

El AED no solo sirve para comprender la estructura básica de los datos, sino también para formular hipótesis preliminares que puedan guiar investigaciones más avanzadas. Antes de realizar este análisis, es indispensable identificar posibles problemas en los datos, como la presencia de errores, valores atípicos o datos faltantes, lo que lleva a la necesidad de la limpieza de datos antes de realizar análisis más profundos. Además de la limpieza, puede ser necesaria una etapa de transformación de datos, con el objetivo de simplificar el dominio de estudio.

¿Qué es la limpieza de datos y cuáles son sus beneficios?

La limpieza de datos (Data Cleaning) es el proceso de detectar, corregir y/o eliminar cualquier error o inconsistencia en los datos con el objetivo de asegurar que la información sea precisa, consistente y utilizable.

Los datos de mala calidad cuestan a las organizaciones y a los científicos de datos un tiempo considerable en corregirlos. De forma general , esta etapa del proceso puede consumir hasta un 60% del tiempo total de un proyecto de ciencia de datos. Pero, ¿por qué no podemos utilizar datos sin procesar en lugar de dedicar tanto tiempo a limpiarlos? El uso de datos sin procesar ("datos crudos") sin realizar una adecuada limpieza y preprocesamiento puede llevar a interpretaciones erróneas, conclusiones sesgadas y resultados poco confiables, por lo que es crucial dedicar tiempo a la limpieza de datos antes de analizarlos. Estos son los errores más comunes que encontramos en un dataset:

- Entradas mal escritas: se deben a errores tipográficos, ortográficos y de medición, que si no se corrigen estos pueden provocar malas categorizaciones dentro del conjunto y afectar negativamente la validez de los resultados y las conclusiones obtenidas.
- Formatos inconsistentes: La inconsistencia en el formato de los datos puede dificultar su análisis. La estandarización de formatos durante la limpieza facilita la interpretación y comparación de variables. Por ejemplo, las fechas, los números o las categorías pueden representarse en distintos formatos dentro del mismo conjunto de datos.
- Valores atípicos (outliers) o erróneos: Las entradas inusuales o erróneas pueden dar lugar a análisis inexactos ya que pueden distorsionar significativamente la media de un conjunto de datos, las medidas de dispersión tales como la desviación estándar e impacto en modelos predictivos como regresiones lineales. Por lo tanto si se realizan inferencias estadísticas sobre la población basadas en una muestra que contiene valores atípicos, los resultados pueden estar sesgados y no representar adecuadamente la población. Es importante señalar que no todos los valores atípicos son necesariamente problemáticos; algunos pueden contener información valiosa o ser indicativos de eventos significativos en el fenómeno estudiado. Sin embargo, es crucial evaluar cuidadosamente el impacto de los valores atípicos en el contexto específico de análisis y considerar estrategias adecuadas para manejarlos.
- Valores nulos o faltantes: Los datos incompletos pueden ser problemáticos, especialmente si su ausencia no es aleatoria. La imputación o eliminación adecuada de datos faltantes es esencial para evitar sesgos y asegurar la representatividad del conjunto de datos.
- Registros duplicados: La presencia de datos redundantes pueden conducir a estadísticas y conclusiones inexactas.Estos duplicados pueden surgir debido a diversos motivos, como errores de entrada de datos, problemas en la recolección de información o la fusión de conjuntos mal gestionados de datos.
- Unidades no estandarizadas: La presencia de unidades no estandarizadas puede dificultar la interpretación precisa de los datos y afectar la calidad de los análisis realizados. Por ejemplo, imagine un conjunto de datos que registre distancias de un cliente respecto a un punto de atención al público de una empresa, donde algunas observaciones están en kilómetros mientras que otras están en millas. Esta falta de estandarización en las unidades puede complicar la comparación directa de las alturas y distorsionar los resultados del análisis.

Por lo tanto, analizando los distintos tipos de errores en el conjunto de datos y viendo los problemas que nos pueden ocasionar podemos concluir directamente que el tiempo dedicado a la limpieza de datos es una inversión importante para garantizar la calidad, la confiabilidad y la validez de cualquier análisis subsiguiente. Ignorar este paso puede conducir a resultados engañosos y a decisiones basadas en información defectuosa.

2. Transformación: Normalización, discretización y binarización de variables

Normalización

Luego de realizar la etapa de limpieza de datos y antes de realizar el análisis exploratorio, es posible realizar la normalización de ciertas variables. Esto se refiere al proceso mediante el cual se ajustan los valores de una variable para que estén dentro de una escala común o comparable. Este proceso es especialmente útil cuando se están utilizando algoritmos o modelos que son sensibles a la escala de las variables.

Lo que se busca es transformar los valores de una variable para que estén dentro de un rango específico, como por ejemplo [0, 1], o [-1, 1], manteniendo la proporción de los valores originales. Esto puede realizarse mediante diferentes métodos, pero uno de los más comunes es la normalización min-max.

La normalización min-max ajusta los valores de la variable de manera que el valor mínimo se transforma en 0 y el valor máximo se transforma en 1, y los demás valores se escalan proporcionalmente entre estos dos límites. La fórmula para la normalización min-max es:

$$X_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

donde x es el valor original de la variable, x_{min} es el valor mínimo de la variable, x_{max} es el valor máximo de la variable, y x_{norm} es el valor normalizado.

La normalización de datos es importante en la ciencia de datos porque ayuda a asegurar que las variables estén en la misma escala, lo que facilita la comparación y el análisis de las variables. Además, puede mejorar el rendimiento de algunos algoritmos de machine learning que son sensibles a la escala de las variables, como el descenso del gradiente en redes neuronales o el algoritmo de k-means en clustering.

Discretización

La discretización de una variable es un proceso mediante el cual se transforma una variable continua en una variable discreta, dividiendo su rango en intervalos o categorías. Esto puede ser útil en varios contextos, como simplificar modelos, reducir la sensibilidad a los valores atípicos o adaptarse a requisitos específicos de análisis. Existen varias técnicas para discretizar una variable continua:

- Discretización en intervalos iguales: Esta técnica implica dividir el rango de valores de la variable en intervalos de igual longitud. Por ejemplo, se podría dividir la variable de edad en grupos de 0-10, 11-20, 21-30, y así sucesivamente.
- Discretización en intervalos basados en cuantiles: En esta técnica, los datos se dividen en intervalos de tal manera que cada intervalo contiene aproximadamente el mismo número de observaciones. Por ejemplo, se podría dividir la variable de ingresos en quintiles, donde cada quintil contiene el 20% de las observaciones.
- Discretización basada en límites predefinidos: Se establecen límites predefinidos para dividir los datos en categorías. Por ejemplo, se podría discretizar una variable de temperatura en "frío", "templado" y "caliente" utilizando límites de temperatura específicos.

La elección de la técnica de discretización depende del contexto específico del problema y de los objetivos del análisis o modelado. Es importante tener en cuenta que la discretización puede introducir cierta pérdida de información, por lo que debe realizarse con cuidado y consideración.

Binarización

La binarización de una variable es un proceso mediante el cual se convierte una variable numérica en una variable binaria, es decir, una variable que toma solo dos valores posibles. Esta técnica es un caso especial de la anterior (discretización) y es útil en diversas situaciones. La binarización de una variable implica establecer un umbral (threshold) y asignar valores de 0 o 1 dependiendo de si el valor original de la variable es mayor o menor que ese umbral. Por ejemplo, si se aplica la binarización a una variable de temperatura y se establece un umbral de 30°C, cualquier temperatura por encima de 30°C se podría codificar como 1 (indicando "caliente") y cualquier temperatura por debajo de 30°C se podría codificar como 0 (indicando "frío").

Este proceso es útil cuando se desea simplificar el análisis o cuando se están utilizando algoritmos de aprendizaje automático que requieren entradas binarias. Por ejemplo, en la clasificación de correos electrónicos como spam o no spam, se podría binarizar una variable que representa la frecuencia de ciertas palabras en el correo electrónico, codificando 1 si la frecuencia supera un umbral específico y 0 en caso contrario.

La binarización de variables puede realizarse utilizando diferentes enfoques, como establecer un umbral fijo, definir el umbral a través de técnicas de selección de características o utilizar técnicas de discretización. Es importante seleccionar el umbral adecuado y considerar las implicaciones del proceso de binarización en el contexto específico del análisis o modelado que se está realizando.

3. Análisis exploratorio de datos

El Análisis Exploratorio de Datos (AED) se utiliza para investigar conjuntos de datos y resumir y determinar sus características principales, a menudo empleando métodos de visualización. Este análisis ayuda a determinar la mejor manera de gestionar las fuentes de datos para obtener las respuestas que se necesitan, lo que facilita que se descubran patrones, se detecten anomalías, se prueben hipótesis o se verifiquen suposiciones, se identifiquen errores, se detecten valores atípicos o eventos anómalos como así también encontrar relaciones interesantes entre las distintas variables.

AED se utiliza principalmente para ver qué pueden revelar los datos más allá del modelado formal o tarea de prueba de hipótesis y proporciona una mejor comprensión de las variables del conjunto de datos y las relaciones entre ellas. También puede ayudar a determinar si las técnicas estadísticas que está considerando para el análisis de datos son apropiadas. Desarrolladas originalmente por el matemático estadounidense John Tukey en la década de 1970, las técnicas AED continúan siendo un método ampliamente utilizado en el proceso de descubrimiento de datos en la actualidad.

¿Por qué es importante el análisis exploratorio de datos?

El objetivo principal del AED es ayudar a analizar, comprender y descubrir características de los datos en lugar de hacer suposiciones sobre los mismos sin ningún respaldo ni garantía estadística. Una vez que el AED está completo y se obtienen los insights (Indicadores), sus características se pueden usar para un análisis o modelado de datos más sofisticado, incluyendo el machine learning.

¿Procedimiento del análisis exploratorio?

Una vez concluidas las etapas de recolección y limpieza de datos se inicia con la etapa de análisis exploratorio. La diferencia entre el análisis exploratorio y la estadística clásica es que esta última tiene por objetivo extraer conocimiento a partir de la información (principalmente) numérica mediante métodos formales, mientras que el análisis exploratorio de datos (o estadística descriptiva) tiene por objetivo identificar las principales características de un conjunto de datos mediante un número reducido de gráficos y/o números. Ambos enfoques son importantes y complementarios en el análisis de datos, y se utilizan de manera conjunta para obtener una comprensión completa de los datos.

El análisis exploratorio se puede clasificar de acuerdo a la cantidad de variables que se analizan al mismo tiempo:

- Análisis Univariado: El análisis univariado se centra en el estudio de una única variable a la vez, es decir, examina las propiedades y características de una variable de interés sin considerar la relación con otras variables. Algunos métodos comunes utilizados en el análisis univariado incluyen:
    - Medidas como la media, mediana, moda, desviación estándar, mínimo, máximo y percentiles, que describen la tendencia central, dispersión y forma de la distribución de la variable.
    - Gráficos como histogramas, gráficos de barras, diagramas de caja, diagramas de torta y curvas de densidad de probabilidad, que proporcionan una representación visual de la distribución de la variable y sus características.
    - Pruebas estadísticas univariadas para evaluar si la distribución de una variable sigue una cierta distribución teórica.

El análisis univariado es útil para comprender la distribución y las propiedades de una variable de interés por sí misma, lo que proporciona información valiosa para la toma de decisiones y la generación de hipótesis en una variedad de disciplinas.

- Análisis Bivariado: El análisis bivariado implica el estudio simultáneo de dos variables para entender la relación o asociación entre ellas. Examina cómo una variable (llamada variable independiente o predictor) puede influir en otra variable (llamada variable dependiente o respuesta). Algunas técnicas comunes utilizadas en el análisis bivariado son:
    - Gráficos de dispersión para visualizar la relación entre dos variables continuas.
    - Coeficientes de correlación como pueden ser la de Pearson o la de chi-cuadrado, que cuantifican la fuerza y la dirección de la relación lineal entre dos variables continuas.
    - Análisis de regresión para modelar la relación entre una variable independiente y una variable dependiente, permitiendo predecir los valores de la variable dependiente en función de los valores de la variable independiente.

El análisis bivariado es esencial para comprender cómo interactúan dos variables entre sí y puede proporcionar información importante sobre relaciones causales o predictivas en los datos. Sin embargo, es importante recordar que la correlación no implica causalidad y que otros factores pueden influir en la relación observada entre las variables.

- Análisis Multivariado: El análisis multivariado implica el estudio simultáneo de tres o más variables para comprender relaciones complejas entre ellas. Se centra en entender cómo múltiples variables se relacionan entre sí y cómo influyen en un fenómeno de interés. Algunas técnicas comunes utilizadas en el análisis multivariado incluyen:
    - Análisis de componentes principales para reducir la dimensionalidad de los datos y explorar la estructura subyacente en múltiples variables.

- Análisis de conglomerados (cluster analysis) para identificar grupos o patrones naturales en los datos basados en múltiples variables.
- Análisis de regresión múltiple: para modelar la relación entre una variable dependiente y múltiples variables independientes, teniendo en cuenta las interacciones entre ellas.
- Análisis factorial: para identificar factores latentes que subyacen en múltiples variables observadas.

El análisis multivariado es fundamental para comprender fenómenos complejos que involucran múltiples variables y puede proporcionar información valiosa para la toma de decisiones en una variedad de campos, incluyendo la investigación científica, el marketing, la economía y la sociología.

En esta Unidad nos centraremos en el Análisis Univariado y en el Análisis Bivariado de datos.

4. Análisis univariado

Para describir un conjunto de datos se comienza con un análisis individual de cada variable (análisis univariado) y posteriormente se estudian las relaciones entre ellas (análisis bivariado y multivariado). Para analizar cada una de las variables del conjunto de datos individualmente se suele comenzar con representaciones gráficas y posteriormente se realizan resúmenes o calculan medidas numéricas.

En primer lugar debemos determinar de qué tipo de variable estamos hablando. Las variables en estadística y análisis de datos pueden clasificarse en diferentes tipos según su naturaleza y la forma en que se pueden medir o categorizar (Ver figura 1).

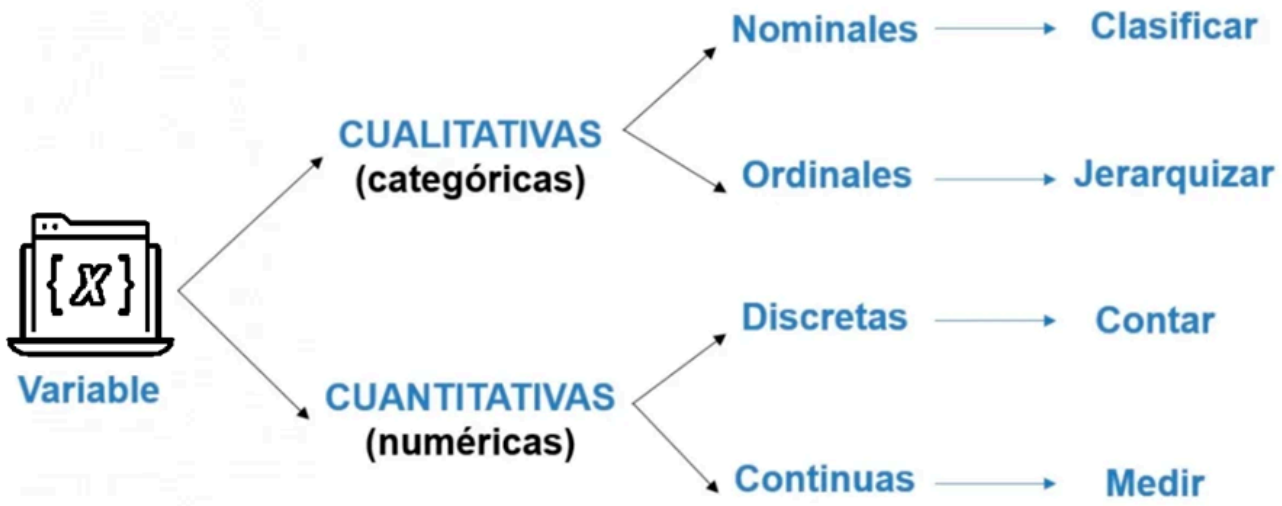

Figura 1: Tipos de variables

De manera general podemos clasificar a las variables como cualitativas y cuantitativas. Las variables cualitativas, también llamadas categóricas, representan características o cualidades de los elementos y se clasifican en diferentes categorías o grupos. Por otro lado, las variables cuantitativas representan cantidades numéricas o magnitudes que se pueden medir o contar.

A su vez, las variables cualitativas se dividen en dos subtipos: nominales y ordinales. Las variables nominales representan características o cualidades que no tienen un orden inherente y simplemente clasifican a los elementos en diferentes categorías o grupos. Por ejemplo, la nacionalidad o género de una persona son variables nominales, ya que las categorías no tienen un orden específico. Por otro lado, las variables ordinales representan características o cualidades que tienen un orden o jerarquía natural entre las categorías. Aunque las categorías siguen siendo mutuamente excluyentes, su posición relativa refleja un orden de importancia o prioridad. Por ejemplo, el nivel educativo (primaria, secundaria, universitaria) y el grado de satisfacción (bajo, medio, alto) son variables ordinales, ya que existe un orden implícito entre las categorías.

Dentro de las variables cuantitativas, existen dos subcategorías principales: variables cuantitativas continuas y variables cuantitativas discretas. Las variables cuantitativas continuas representan cantidades numéricas que pueden tomar cualquier valor dentro de un rango específico, siendo infinitamente divisibles. Ejemplos de este tipo de variables podrían ser la altura, el peso, la temperatura y el tiempo. Mientras que las variables cuantitativas discretas representan cantidades numéricas que solo pueden tomar valores enteros y no pueden ser divididas infinitamente. Ejemplos de este tipo de variables pueden ser el número de hijos de una persona, la cantidad de ventas de una empresa en determinado tiempo o el número de veces que ocurre un determinado evento.

La distinción entre variables cualitativas y cuantitativas es esencial en el análisis de datos, ya que determina las técnicas estadísticas adecuadas que se pueden aplicar para su análisis.

¿Qué podemos estudiar de una variable?

Hay varios aspectos que se pueden estudiar en una variable dependiendo de su tipo y naturaleza. Algunas de las características más comunes que se pueden analizar en una variable son:

- Distribución de frecuencia: Se puede examinar la distribución de frecuencia para comprender cómo se distribuyen los valores de la variable a lo largo de sus diferentes categorías o rangos.
- Medidas de tendencia central: Se pueden calcular medidas de tendencia central como la media, la mediana y la moda para obtener una idea de dónde se concentran mayormente los valores de la variable.

- Medidas de dispersión: Se pueden calcular medidas de dispersión como la desviación estándar, el rango y el rango intercuartílico para comprender la variabilidad de los datos alrededor de la medida central.
- Visualización: Se pueden utilizar gráficos como histogramas, diagramas de barras, diagramas de caja (boxplot) y diagramas de dispersión para visualizar la distribución y patrones de las variables.
- Valores atípicos: Se pueden identificar y analizar valores atípicos o anomalías que pueden afectar la interpretación de los datos.
- Valores cambiantes: Se puede analizar si existen datos cambiantes bajo ciertos factores como puede ser el tiempo o determinadas condiciones. Si hay datos temporales o condicionalmente cambiantes, se puede estudiar cómo cambia la variable en respuesta a estos factores.

5. Análisis bivariado

Hasta ahora hemos tomado el conjunto de datos y sólo hemos aplicado estadística descriptiva para analizar una sola variable por vez, lo cual NO nos permite establecer si existe algún tipo de relación entre las distintas variables que contiene el conjunto de datos. Por lo tanto, nos proponemos a partir de aquí, analizar las variables en forma simultánea de a pares con el objetivo de encontrar relaciones entre ellas, que nos permitirá describir las dos variables de forma conjunta o una (variable dependiente) en función de la otra (variable independiente o explicativa).

Para realizar el análisis bivariado podemos tomar pares de variables de cualquier tipo, por lo que tenemos tres posibles combinaciones desde este punto de vista:

1. Cuantitativa – Cuantitativa
2. Cualitativa – Cualitativa
3. Cuantitativa – Cualitativa

En el figura 2 se muestran algunas (no son las únicas) de las técnicas más empleadas en ciencia de datos para el análisis de dos variables de acuerdo al tipo de cada una de ellas:

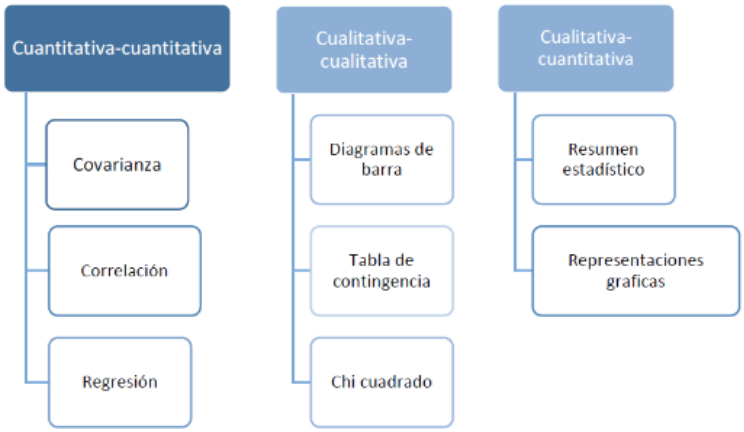

Figura 2: Técnicas de análisis de dos variables

Análisis de ambas variables cualitativas

Tablas de contingencia
Uno de los métodos más utilizados cuando queremos analizar dos variables cualitativas es la tabla de contingencia (término introducido por Karl Pearson en 1904). La tabla contiene en cada celda la correspondiente frecuencia conjunta que representa el número de datos que pertenecen a la entrada i-ésima de la primera variable y a la entrada j-ésima de la segunda. A partir de dicha tabla podemos estudiar si las dos variables son o no independientes. Si son independientes no existe relación alguna entre ellas; en caso contrario analizaremos el tipo y el grado de su dependencia tanto gráfica como numéricamente.

Diagramas de barra

Otro método muy utilizado es mediante diagramas de barra (o similares). Estos diagramas constituyen una herramienta gráfica, la cual nos permite una visualización simple y comparativa entre los datos (ver figura 3).

Figura 3: Tipos de gráficos de barras

Test Chi-cuadrado de independencia

La prueba de independencia de Chi-Cuadrado (X2) es un método comúnmente utilizado para analizar la relación entre dos variables cualitativas. Esta prueba estadística evalúa si las frecuencias observadas en una tabla de contingencia difieren significativamente de las frecuencias esperadas si las dos variables fueran independientes. En otras palabras, determina formalmente si existe una asociación significativa entre las dos variables. Si el valor p resultante es menor que un nivel de significancia predeterminado, se concluye que hay una asociación significativa entre las dos variables. Este análisis es fundamental para comprender las relaciones entre diferentes características o atributos en un conjunto de datos.

El test Chi-Cuadrado de independencia inicia planteando dos tipos de hipótesis: la hipótesis nula, llamada H0 (las muestras son independientes), y la hipótesis alternativa, denotada como H1, (las muestras están correlacionadas). Se construye la tabla de contingencia que muestra las frecuencias conjuntas de las diferentes categorías de las de las dos variables cualitativas. Luego, se calcula la estadística de Chi-cuadrado, que mide la discrepancia entre las frecuencias observadas y esperadas en la tabla de contingencia. Esta estadística se calcula sumando los cuadrados de las diferencias entre las frecuencias observadas y esperadas, divididas por las frecuencias esperadas para cada celda de la tabla:

$$X^2 = \sum_{i=1}^{n} \frac{(O_k - E_k)^2}{E_k}$$

Donde O_k es la frecuencia observada y E_k la frecuencia esperada. Una vez calculada la estadística de Chi-cuadrado, se compara con un valor crítico de la distribución de Chi-cuadrado con un grado de libertad adecuado y un nivel de significancia predefinido. Si el valor de Chi-cuadrado calculado es mayor que el valor crítico, se rechaza la hipótesis nula y se concluye que hay una asociación significativa entre las dos variables. En caso contrario, no hay suficiente evidencia para rechazar la hipótesis nula y se concluye que no hay una asociación significativa entre las variables.

Puede ver en el siguiente link un ejemplo simple de la utilización de esta técnica:

- https://datatab.es/tutorial/chi-square-test

Análisis de ambas variables cuantitativas

La distribución conjunta de dos variables puede expresarse gráficamente mediante un diagrama de dispersión, nos proporciona una buena descripción de la relación entre las dos variables. También tenemos los métodos numéricos como la correlación y la regresión que nos permitirán cuantificar estas relaciones.

Covarianza

La covarianza es una medida de variación conjunta de las dos variables en estudio. La cuantificación de la covarianza consiste en la construcción de coeficientes que nos permitan integrar en un valor estimado, información con respecto a la varianza conjunta entre dos variables y tiene como objetivo fundamental definir la magnitud y el sentido de la relación entre las variables. De este modo, el análisis conjunto de las varianzas de dos variables (regularmente definidas como X y Y) nos permite identificar la relación empírica entre éstas, entendiendo por relación el ajuste de los datos a una función lineal estocástica subyacente. Lo definimos mediante:

$$S_{xy} = \frac{\sum_{i=1}^{N}(x_i - \bar{x}) \times (y_i - \bar{y})}{N}$$

¿Cómo interpretamos el valor de S_{xy}?

- Si $S_{xy} > 0$ Relación lineal positiva.
- Si $S_{xy} < 0$ Relación lineal negativa.
- Si $S_{xy} = 0$ No existe relación lineal o existe relación no lineal.

Análisis de correlación

La **correlación** es un tipo de asociación entre dos variables cuantitativas. El signo nos indica la dirección de la relación:

- + indica una relación directa o positiva
- - indica relación inversa o negativa

La magnitud nos indica la fuerza de la relación, que toma valores entre -1 a 1. Si la correlación vale 1 o -1 diremos que la correlación perfecta; si el valor es 0 diremos que las variables no están correlacionadas.

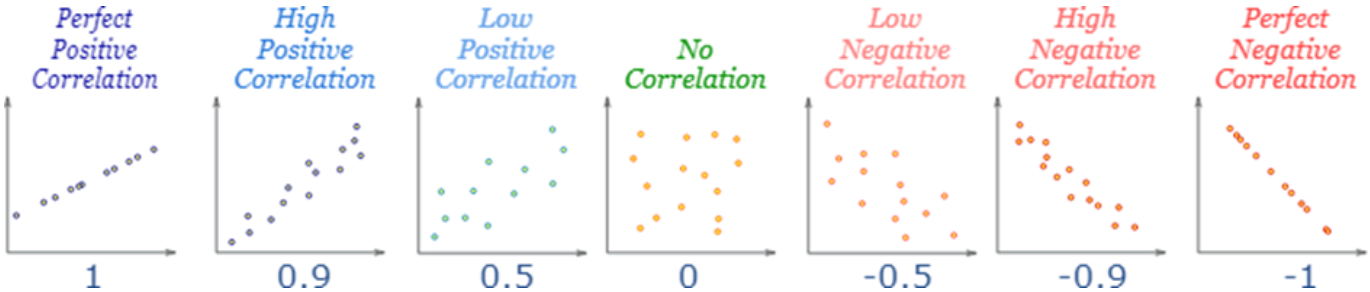

Figura 4: Distintas correlaciones entre los datos

La existencia de una correlación lineal nos evidencia que los datos caminan juntos de un modo algo lineal pero **NO** significa que X cause Y (o viceversa), ya que la correlación es una relación surgida a partir de los datos empíricos. Si una variable X nos causa una variable Y tendríamos una relación de **causalidad** entre ambas.

Regresión lineal simple

El análisis de regresión tiene por objetivo, en principio, obtener la función matemática que mejor explique una variable cuantitativa Y (variable dependiente o a explicar) a partir de otra variable cuantitativa X (variable independiente o explicativa); posteriormente, el análisis de regresión se extiende pudiéndose explicar una variable (o más), cuantitativa o, incluso, cualitativa, a partir de varias variables cuantitativas y cualitativas. Además de la finalidad explicativa, el análisis de regresión permitirá predecir valores de la variable dependiente para distintos valores de la independiente.

Así, se intenta explicar Y mediante *f(X)*, función de *X* que se aproxima a *Y* pero no coincide exactamente con Y (las relaciones entre variables no son exactas):

$$Y = f(X)$$

La función f se puede buscar sin ningún tipo de limitación (regresión general de escaso interés práctico) o limitándose a algún tipo de función sencilla (lineal, parabólica, exponencial, ,...), pero el caso más común es el de regresión lineal simple ya que es fácilmente interpretable y los desarrollos matemáticos se facilitan.

En este modelo, se supone que la relación entre las variables es lineal, es decir, se puede representar mediante una línea recta. La ecuación de la **regresión lineal simple** tiene la forma:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Donde:

- *Y* es la variable dependiente que se está tratando de predecir.
- *X* es la variable independiente que se utiliza para hacer la predicción.
- $ß_0$ es el sesgo (intersección de la línea de regresión con el eje *Y*)
- $ß_1$ es la pendiente de la línea de regresión, que representa el cambio en *Y* por unidad de cambio en *X*.
- ε es el término de error, que representa la variabilidad no explicada por el modelo.

El objetivo de la regresión lineal simple es estimar los coeficientes $ß_0$ y $ß_1$ que minimizan la suma de los cuadrados de los errores (es decir, la diferencia entre los valores observados y los valores predichos por el modelo). Esto se logra utilizando métodos como el método de mínimos cuadrados ordinarios. Una vez que se ha ajustado el modelo de regresión lineal simple, se pueden realizar varias inferencias y análisis, como evaluar la significancia de los coeficientes, hacer predicciones sobre nuevos datos, calcular intervalos de confianza para las predicciones y evaluar la bondad del ajuste del modelo. La regresión lineal simple es un método versátil y ampliamente utilizado para modelar y comprender las relaciones entre variables.

Análisis de una variable cuantitativa y otra cualitativa

Cuando se realiza un análisis entre una variable cuantitativa y otra cualitativa, el estudio se enfoca como un problema de comparación entre comportamiento de la variable numérica en las diferentes subpoblaciones que define la variable cualitativa. Esto implica examinar si existe alguna asociación o diferencia significativa entre los valores de la variable cuantitativa y los grupos definidos por la variable cualitativa. Se debe tener especial cuidado en no ignorar la heterogeneidad del conjunto de datos debido a la presencia de subpoblaciones, ya que esto puede conducir a conclusiones equivocadas en el análisis.

Resúmenes estadísticos

Los resúmenes estadísticos resultan muy útiles cuando queremos analizar el comportamiento de la variable cuantitativa para cada una de las categorías de la variable cualitativa en términos de estadística descriptiva. Colocamos en las filas las distintas categorías de la variable cualitativa y en las columnas realizamos el análisis univariado de la variable cuantitativa como si cada categoría fuese una variable distinta. El resumen estadístico proporciona una descripción concisa de las características clave de una variable cuantitativa, y puede ser útil para comparar estas características entre diferentes grupos definidos por la variable cualitativa.

Diagrama de caja y bigotes (box-plot)

Un diagrama de caja y bigotes (figura 5), también conocido como boxplot, es una herramienta gráfica que proporciona una representación visual de la distribución de un conjunto de datos y permite identificar valores atípicos.

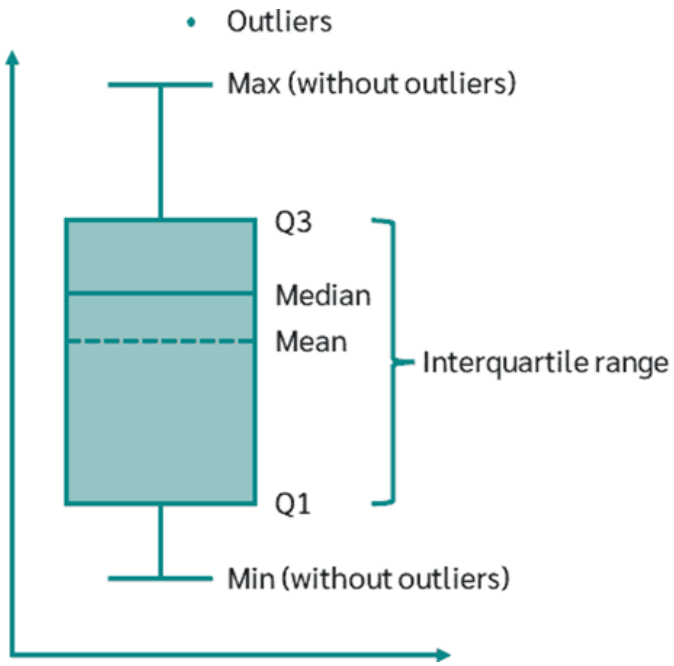

Figura 5: Box-Plot

Las líneas que se extienden paralelas a las cajas se conocen como «bigotes», y se usan para indicar variabilidad fuera de los cuartiles superior e inferior. Los valores atípicos (outliers) se representan como puntos individuales que están en línea con los bigotes. Los diagramas de cajas y bigotes se pueden dibujar vertical u horizontalmente.

Estos diagramas son una excelente forma de examinar rápidamente uno o más conjuntos de datos gráficamente. Aunque parezcan primitivos en comparación con otros diagramas tienen la ventaja de ocupar menos espacio, lo cual es útil cuando se comparan distribuciones entre muchos grupos o conjuntos de datos.

Bibliografía

- Denis, D. (2020). Univariate, Bivariate, and Multivariate Statistics Using R: Quantitative Tools for Data Analysis and Data Science. Willey.
- Lind, Douglas (2015). Estadística aplicada a los Negocios y la Economía, 16ª Edición, Editorial MCGraw- Hill.
- Walpole, R.E., Myers, R.H., Myers, S.L., Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias. Pearson.
- Salvador Figueras, M y Gargallo, P. (2003). Análisis Exploratorio de Datos. http://www.5campus.com/leccion/aed